## EIS WS1516 - Meilenstein 2

 $\label{thm:continuous} \mbox{ Verteiltes Training einer automatisierten Dokumentenattributierung } \\ \mbox{ Tim Howe}$ 

# Inhaltsverzeichnis

D0	nänenrecherche	4
1.1	Allgemeine Verarbeitungprozess	4
1.2	Begrifflichkeiten	4
	1.2.1 Attributierung	4
	1.2.2 Strukturierungsgrad	5
	1.2.3 Geschäftsobjekt	6
1.3	Anwendungsfelder	
1.4	Nutzungsmerkmale	7
Mar	ktrochorcho	g
		_
	"	
2.3	Obersicitt	10
Anfo	orderungsanalyse	11
3.1	Stakeholder	11
3.2	Nutzerprofile	11
3.3	Nutzungsziele	11
_		
•		12
	·	
4.3	Geschäftsobjekt	13
7iell	nierarchie	14
-		
0.0		-
Allei	instellungsmerkmale	15
D		16
F102	ess essential and the second essential and the	10
Kon	nmunikationsmodel	17
8.1	Deskriptiv	17
8.2	Kommunikationsdiagramm	18
8.3	Präspriktiv	19
8.4	Kommunikationsdiagramm	
		•
		20
9.2	Variante 2: Nachrichten orientiert	20
Risil	gen	21
		21
	1.1 1.2 1.3 1.4 Mar 2.1 2.2 2.3 Anfo 3.1 3.2 3.3 Syst 4.1 4.2 4.3 Ziell 5.1 5.2 5.3 Allei Proz Kon 8.1 8.2 8.3 8.4 Proz 8.4 Proz 9.2 9.2 Proz 9 Proz 9.2 Proz 9 Proz 9 Proz 9 Proz 9 Proz 9 Proz 9 Proz 9 Proz 9 Proz 9 Proz 9 Proz 9 Proz 9	1.1 Allgemeine Verarbeitungprozess 1.2 Begrifflichkeiten 1.2.1 Attributierung 1.2.2 Strukturierungsgrad 1.2.3 Geschäftsobjekt 1.4 Nutzungsmerkmale  Marktrecherche 2.1 Codia DMS 2.2 InPunkto 2.3 Übersicht  Anforderungsanalyse 3.1 Stakeholder 3.2 Nutzerprofile 3.3 Nutzungsziele  Systembeschreibung 4.1 Komponenten 4.2 Nutzerrollen 4.3 Geschäftsobjekt  Zielhierarchie 5.1 Strategisch 5.2 Taktisch 5.3 Operational  Alleinstellungsmerkmale  Prozess  Kommunikationsmodel 8.1 Deskriptiv 8.2 Kommunikationsdiagramm 8.3 Präspriktiv 8.4 Kommunikationsdiagramm 8.3 Präspriktiv 8.4 Kommunikationsdiagramm 8.4 Prözeptieketundiagramm 8.5 Präspriktiv 8.6 Kommunikationsdiagramm 8.7 Präspriktiv 8.8 Kommunikationsdiagramm 8.8 Präspriktiv 8.8 Kommunikationsdiagramm

INHALTSVERZEICHNIS 3

11 Proof of Concepts	22
11.1 Definition	22
11.1.1 Architektur	
11.1.2 Regel-Engine	
11.1.3 mobiler Client	
11.1.4 technisch: Steuerung Dienst	
11.1.5 •	
11.2 Durchführung	22
12 Methodischer Rahmen	23
13 Projektplan	24
14 Quellen	25

# Domänenrecherche

Im folgenden werden die wichtigsten Themen der Anwendungsdomäne beschrieben und einer ersten Bewertung hinsichtlich projektrelevanter Eigenschaften unterzogen.

## 1.1 Allgemeine Verarbeitungprozess

Beispielhaft die wichtigsten funktionalen Komponenten des Dokumentenverabreitungsprozesses beschrieben, wichtig bleibt anzumerken das in konkreten Implementierungen die Funktionalitäten verschwimmen und keine klare Trennung wie hier beschrieben vorherrscht(?).

#### 1. Extraktion:

Manuelles oder mittels OCR automatisiertes auslesen von Informationen aus einer Dokumentendatei oder einer zugehörigen Bitmapdatei.

- (a) optional Nacherfassung:
  Kontrolle der OCR Ergebnisse und ggf Korrektur bei unzureichender Extraktionsqualität
- 2. Klassifizierung:

Beschreibt die Einordnung in eine klar abgegrenzte Menge von Dokumenttypen wie zb. Formulare, Rechnungen, Lieferscheine, Bewerbungen.

- 3. Attributierung:
  - Beschreibt den Prozess der Zuordnung von organisations- oder fachspezifischen Attributen zu einem Dokument zur weiteren Verarbeitung innerhalb der Organisation. Die können zum Beispiel Buchungskonten, Kostenstellen, Projektnummern oder Anprechpartner sein.
- 4. Export & weitere Verarbeitung:

Übergabe der klassifizierten und attributierten Dokumente an einem betriebliches Anwendungssystem zur Buchung, Kontierung oder Archivierung.

## 1.2 Begrifflichkeiten

#### 1.2.1 Attributierung

In der Praxis wird der Begriff der Attributierung für zweierlei Aspekte verwendet:

- 1. semantische(?) Attributierung:
  - Extrahierung und Zuordnung von Metainformationen zu einem Dokument welche sich auf das Dokument, bzw die Dokumentendatei als Repräsentation des Dokuments, selbst beziehen. Dies können zb Schlagworte, Speicherort ... sein.
- 2. fachliche Attributierung:
  - Die fachliche Attributierung ist ein Teil des Arbeitsprozesses bei welchem dem Dokument Attribute zugeordnet werden die Diese Attribute können zb kaufmännischer, steuerlicher oder juritischer Natur sein.

Für dieses Projekt wird der Begriff im Sinne der fachlichen Attributierung verwendet.

### 1.2.2 Strukturierungsgrad

Der Strukturierungsgrad eines Dokuments wird beschrieben durch das Ausmaß an Sicherheit mit der ein Wert eines Dokumentenattributs an einer Position im Dokument auftritt und welcher Wertebereich in diesem abgebildet wird.

- 1. unstrukturiert: gar keine bis geringe Positionssicherheit mit überwiegend undefiniertem Wertebereich, zb. Bewerbungsschreiben
- 2. semi-strukturiert: gute Positionssicherheit mit überwiegend definiertem Wertebereich, zb. Rechnungen, Lieferscheine
- 3. strukturiert: absolute Positionssicherheit mit klar definiertem Wertebereich, zb. genormte betriebliche oder behördliche Formulare

Mit dem Strukturierungsgrad steigt die semantische Spezialisierung sowie das Automatisierungspotential für diesen Dokumenttyp.

### 1.2.3 Geschäftsobjekt

Im Kontext der Anwendungsdomäne wird das zentrale verarbeitete Geschäftsobjekt aus einer Menge von Dokumentendatei und zugeordneten beschreibenden Daten gebildet. Das Dokument liegt dabei in der Regel als Repräsentation im Dokumentformat .pdf, als .tiff oder .jpg Bitmapdatei und die beschreibenden Daten als .xml Datei vor.

## 1.3 Anwendungsfelder

Tabelle 1.1: Automatisierte Dokumentenverarbeitung				
Domäne	Primäre Dokumenttypen	Strukturierungs- grad	wirtschaftliche Relevanz	
Buchhal- tung	Rechnungen	2	++	
Verwaltung	Formulare	3	+	
Personal	Bewerbungen	1-2	0	
Kanzleien	Schriftverkehr	1	+	
Logistik	Lieferscheine	2	+	

2

1

3

Services für Privatanwender

nicht etabliert

## 1.4 Nutzungsmerkmale

Rechnungen

Formulare

Versicherungen

Privat

Eine erste kurze Betrachtung der antizipierten Nutzungsmerkmale welche Entscheidungen zu Anwendungsdomäne (ref), Objektbereich (ref) und ... unterstützen soll.

	Tabelle 1.2: Nutzungsmerkmale		
Domäne	Arbeitsumgebung	Arbeitsgerät(?)	
Organisationsrolle			
Buchhaltung	Büro	Desktop PC	
Bürokfm Fachkraft			
Verwaltung	Büro	Desktop PC	
Bürokfm oder Verwaltungs- Fachkraft			
Personal	Büro	Desktop PC	
Personaldienstleistungskfm Fachkraft			
Kanzleien	Büro	Desktop PC	
Bürokfm Fachkraft			
Logistik	Büro	Desktop PC	
	ggf Mobil, in größeren Betrieben	ggf Tablet	
Bürokfm Fachkraft, Lagerist			
Privat	Zuhause	Desktop PC	
	Mobil	Tablet, Smartphone	
Privat, Organisieren von Post(?)			

# Marktrecherche

Der Markt wird im allgemeinen von Entwicklern einzelner Komponenten und Systemhäusern bestimmt die Fremdkomponenten ggf mit Eigenentwicklungen kombinieren und so individuelle Lösungspakete schnüren welche sich immer an den in beschrieben etablierten ??Prozess der Anwendungsdomäne orientieren. Die Komponenten lassen sich grob in die folgenden Bereiche enteilen:

• Capture: Scannen, OCR, klassifizieren

• Workflow: Attributierung

• betriebliche Anwendungssysteme: Buchhaltung, Archivierung

Zudem sind OEM Versionen glossar durchaus gängige Praxis wodurch eine Einsicht erschwert wird. Um dennoch einen Eindruck in die Marktsituation zu gewinnen hilft eine Betrachtung der og Bereiche in der funktional übergeordneten Ebene der DMS-Systeme, ... und deren Eigenschaften. Es werden Ansätze zweier Anbieter exemplarisch beschrieben und eine Einordnung zwischen diesen Lösungen und TaARs mittels einer Featurematrix ermöglicht.

### 2.1 Codia DMS

Codia DMS bietet auf Basis des d3.ecm von d.velop spezialisierte Lösungen im eGovernment Umfeld für öffentliche Verwaltung und Hochschulen mit den Themen Scannen Klassifizierung, Rechungs- und Eingangspostverarbeitung, eAkte und Archivierung.

### 2.2 InPunkto

InPunkto spezialisert auf Dokumenten Dienstleistungen im SAP Umfeld mit den Themen automatische Erfassung & Verarbeitung, Workflow, eAkte und Archivierung.

# 2.3 Übersicht

Thema	Codia	InPunkto	TaARs
Automatisierte Klassifizierung	J	J	N
Attributierung			
semantisch	J	kA	N
fachlich	J	J	J
Automatisierte Attributierung	N	N	J
Steuerung	lastabhängige Aufgabenverteilung über Workflowsystem	kA	Priorisierung
(Rechnungs) Workflow	d3ecm	SAP Workflow	freie Wahl
Export	d3.ecm	SAP	Rohexport als xml

# Anforderungsanalyse

## 3.1 Stakeholder

Aus der Domaenen- und Marktrecherche lassen sich die folgenden Stakeholder identifizieren: Scanner

Bezeichnung	Beziehung	Merkmal	Erwartung
Verwaltungsangestellte	Interesse	Ausgabe	Information für einzelne Verwaltungs- und Verarbei- tungsprozesse fokussiert
	Anpruch	Ausgabe	Überblick über den Gesamtzu- stand
Fachangestellte	Anspruch	Ausgabe	Informationsmenge auf Ihren Fachbereich fokussiert
	Interesse	Eingabe	
Fach- und Verwaltungsangestellte	Anrecht	Dokumente	Reduktion der zu verarbeiten- den Menge bei gleichbleibender Produktivität
	Interesse	Verarbeitungsschritte	Reduktion
	Anrecht	Abstimmung mit Kollegen	Reduktion des Aufwands fuer Abstimmung
Entscheider	Anspruch	Prozesszustand	Entscheidungsrelevante Informationen zu erhalten
	Anspruch	Prozesssteuerung	flexibel, zeitnah und wirkungs- voll in Abläufe eingreifen
	Interesse	Schnittstellen zw Angestellten und System	produktive Nutzung
	Interesse	Schnittstellen zw Angestellten	effizienter, fehlerarmer Informationsfluss

# 3.2 Nutzerprofile

# 3.3 Nutzungsziele

# Systembeschreibung

Ein allgemeine Beschreibung der wichtigsten Eigenschaften des TaARs , detaillierte Beschreibungen folgen in den zugehörigen Kapiteln

### 4.1 Komponenten

#### Verwaltungsserver

- 1. importiert Rohdaten, erzeugen des Geschäftsobjekts
- 2. prüft Rohdaten auf Vollständigkeit, vorhandene Regeln, falls eine vollständige Regel
  - (a) vorliegt: Übergabe des Geschäftsobjekts an den Regel-Server
  - (b) nicht vorliegt: Übergabe des Geschäftsobjekt an einen Verwaltungsclient
- 3. erhält vervollständigte Geschäftsobjekte von Verwaltungs- und Fachclient
- 4. gibt Informationen zum Systemzustand an Steuerungsclient

#### Verwaltungsclient

- 1. Windows Desktop Client
- 2. erhält unvollständige Geschäftsobjekte vom Verwaltungsserver
- 3. vervollständigt diese Geschäftsobjekte
- 4. sendet vollständige Geschäftsobjekte an Verwaltungsserver
- 5. sendet unvollständige Geschäftsobjekte an Fachclient
- 6. verwaltet angelegte Regeln

#### **Fachclient**

- 1. Windows Desktop Client
- 2. funktionale Untermenge des Verwaltungsclients
- 3. erhält unvollständige Geschäftsobjekte vom Verwaltungsleient
- 4. sendet vollständige Geschäftsobjekte an Verwaltungsserver

### Steuerungsclient

- erhält Informatinen zum Systemzustand vom Verwaltungssserver
- übergibt Priorisierungskommandos an Verwaltungsserver

#### Regel-Server

- 1. erhält Geschäftsobjekt von Veraltungsserver
- 2. berechnet die Anwendung der Regel auf das Geschäftsobjekt
- 3. exportiert das Ergebnis

## 4.2 Nutzerrollen

# 4.3 Geschäftsobjekt

Das verarbeitete Geschäftsobjekt besteht aus den Rohdaten einer Rechnung, den zugehörigen Metadaten und einer zugewiesenen Regel für dieses Geschäftsobjekt.

# Zielhierarchie

### 5.1 Strategisch

Für das Projekt soll ein Anwendungskontext gefunden werden der eine hohe wirtschaftliche Relevanz aufweist. Dies bezieht sich insbesondere auf den zu verarbeitenden Objektbereich des Systems welcher einen Komplexitätsgrad erreichen soll der fachlich relevant und im Projektrahmen beherrschbar ist.

Die Verwaltungs- und Fachangestellten müssen vom Ballast repetitiver Aufgaben befreit werden um so Ressourcen für anspruchsvollere Aufgaben freisetzen. Bei der Lösung müssen die Bedürfnisse der Entscheider an einen veränderten oder neuen Prozess berücksichtigt werden.

Bei der prototypischen Realisierung sollen bezüglich Implementierungstechnologien möglichst viele im antizipierten beruflichen Kontext relevanten Erfahrungen gesammelt werden.

### 5.2 Taktisch

Die Auswahl des Anwendungskontextes und des Objektbereichs soll aus der Analyse der Domänenrecherche, der Marktrecherche sowie der Alleinstellungsmerkmale erfolgen.

Den Verwaltungs- und Fachangestellten soll ein System zur teilweisen Automatisierung von stark repetitiven und intellektuell wenig anspruchsvollen Aufgaben zur Verfügung gestellt werden. Dabei sollen bisher bestehende Aufgaben zu einem Teil durch Verbesserung und Überwachung der Automatisierung ersetzt werden.

## 5.3 Operational

Bei der Domänenrecherche müssen die verarbeiteten Objekte, dh. Dokumentenklassen, berücksichtigt und hinsichtlich Ihrer Komplexität und wirtschaftlichen Relevanz eingeordnet werden.

Das Automatisierungspotential soll mittels einer deskriptiven Aufgabenanalyse und unter Berücksichtigung der Domänen- und Marktrecherche identifiziert werden.

# Alleinstellungsmerkmale

Die Markt- und Domänenanalyse offenbart (hoffentlich!!!) eine Marktlücke für Firmen mit

- 1. mit einem bestehenden Extrahierungsprozess und optionalem Nacherfassungsprozess
- 2. mit einem bestehenden Buchungs- , Kontierung- oder Archivssystem
- 3. Workflow
  - (a) mit bestehendem Workflowsystem oder
  - (b) ohne Bedarf für ein vollintegratives Workflowsystem
- 4. mit Bedarf für eine Automatisierung


#### Slim Clients

### **Automatisierte Attributierung**

freie Wahl des Workflowsystem Für ein Workflowsystem muessen

# **Prozess**

Ausgehend von ??Domaenenrecherche, Prozess eine Darstellung eines exemplarischen Verarbeitungsprozesses und die Intergration des zu entwickelnden TaARs in diesen.



# Kommunikationsmodel

### 8.1 Deskriptiv

#### **Scanner**

Scannen Dokumente ein und leiten diesen einen OCR-Erkennungsprozess weiter.

#### **Erfasser**

Erhalten Dokumente aus dem Erkennungsprozess und korrigieren diese oder führen eine vollständige Erfassung eines Dokumentes durch und leiten dieses an die Verwaltungsangestellten weiter.

### Verwaltungsangestellte

Erhalten Dokumente von den Erfassern und nutzen ein betriebliches Anwendungssystem um diese mit Attributen zu versehen und einem Geschäftsvorgang zuzuordnen. Geben den Geschäftsvorgang an einen Fachangestellten weiter. Stellen bei Problemen mit der Zuweisung oder Attributtierung Rückfragen an Fachangestellte oder in kritischen Fällen an einen Entscheider.


### **Fachangestellte**

Erhalten einen Geschäftsvorgang von Verwaltungsangestellten oder Fachangestellten und ordnen diesem Vorgangsoder Fachbezogene Attribute zu. Beantworten Rückfragen der Fachangestellten und wenden sich bei Problemen mit der Zuweisung an einen entsprechenden Entscheider.

#### Entscheider

Erhalten durch Berichte und Besprechungen Einsicht in bestehende Prozesse und greifen per Anweisung an Verwaltungs- und Fachangestellte in einen Prozess ein. Teilen den Angestellten bei Vorgangsproblemen die durchzuführende Lösung des Problems mit.

## 8.2 Kommunikationsdiagramm



### 8.3 Präspriktiv

### Verwaltungsserver

- übergibt Rohdaten und Regeln an Regel-Engine
- gibt Informationen zum Systemzustand an Steuerungsclient
- erhält Priorisierungsinformation von Steuerungsclient
- übergibt priorisiertes Geschäftsobjekt an Verwaltungsclient

### Steuerungsclient

- erhält Information vom Verwaltsdienst zum Systemzustand
- teilt Verwaltungsdienst die Priorisierung mit

### Verwaltungsclient

- erhält aktuell priorisierte Geschäftsobjekte vom Verwaltungsdienst
- gibt vollständiges Geschäftsobjekt an Verwaltungsdienst zurück
- gibt unvollständiges Geschäftsobjekt an Fachclient (über Verwaltungsdienst)


#### **Fachclient**

- erhält unvollständiges Geschäftsobjekt von Verwaltungsclient (über Verwaltungsdienst)
- gibt vervollständigtes Geschäftsobjekt an Verwaltungsdienst zurück

### Regel-Engine


• erhält Geschäftsobjekt und Regel vom Verwaltungsdienst

## 8.4 Kommunikationsdiagramm



# Architekturdiagramm

## 9.1 Variante 1: API orientiert



### 9.2 Variante 2: Nachrichten orientiert

# Risiken

### 10.1 Architektur

**Zugriffsstruktur & Steuerung** Es muss eine Struktur gefunden werden mit der die folgende Funktionalitäten unabhängig voneinander realisiert werden können:

- 1. Zugriff des Verwaltungsclients auf Geschäftsobjekte
- 2. Übergabe der Geschäftsobjekte von Verwaltungsclient an den Fachclient
- 3. Steuerung der Priorisierung der Geschäftsobjekte

### Steuerungsclient

- 1. kommunikation zu steuerungskomponente im Verwaltungsdienst
- 2. Implementierung von interaktionsparadigmen (?)

**Regel-Engine** Es muss eine Regelform entwickelt werden die die strategischen Ziele 1+2 erfüllt. Definition und Speicherung des Regelobjekts sowie Anwendung der Regeln auf Geschäftsobjekte.

# **Proof of Concepts**

### 11.1 Definition

### 11.1.1 Architektur

Zugriffstruktur

### 11.1.2 Regel-Engine

Ein simpler Poc der folgenden Ansprüchen erfüllt

### 11.1.3 mobiler Client

Bezug: ??Risiken 2.1 Erfolgskriterien:

- ruft Info api des Verwaltungsdienstes auf
- erhält Informationen zum Systemzustand
- stellt diese Informationen dar
- ruft Steuerungs api mit Priorisierungsparameter auf

### Alternative:

Steuerungsfunktion als Browserbasierten Client umsetzen

### 11.1.4 technisch: Steuerung Dienst

11.1.5

## 11.2 Durchführung

# Methodischer Rahmen

# Projektplan

Der Projektplan wird git repo : EISWS1516 $_{H}owe_{P}rojektplan.ods$  geführt.

# Quellen

**Domänenrecherche** - https://de.wikipedia.org/wiki/Dokumentenklasse

- http://www.officemanager.de/glossar/dokumentenmanagement.html
- $\verb|http://dbis.eprints.uni-ulm.de/782/1/Diplomarbeit|_{F} in al.pdf$

http://www.project-consult.de/ecm/content/capture,

 $\label{lem:marker-decomposition} \textbf{Martkrecherche} \quad \text{- isoft: http://www.i-soft-systemhaus.de/fileadmin/templates/pdf/isoft} \\ \text{- } codia: http://www.codia.de/codia/files/dms_in_hochschulenv1.pdf}$